A Time-of-Day-Aware Empirical Study of AWS Spot Instance Reliability for Short-Running Workloads

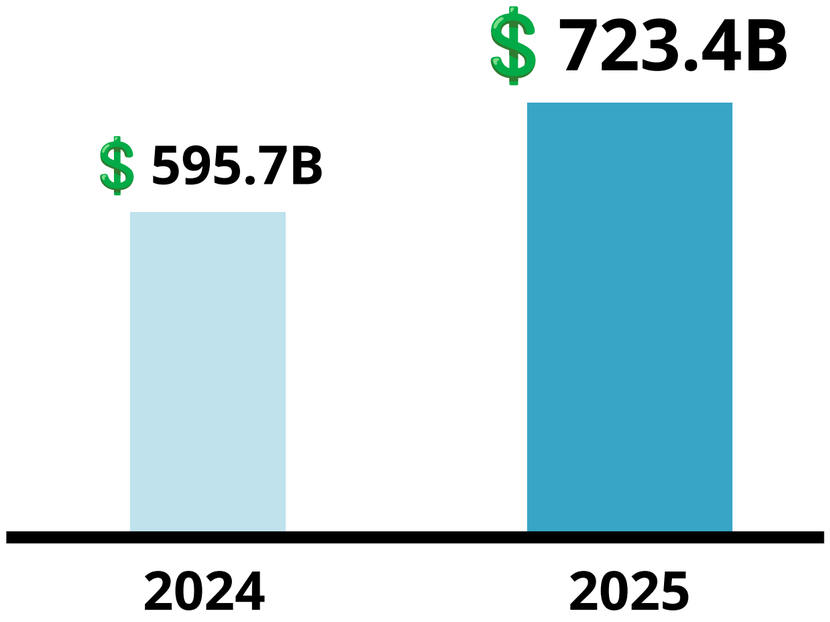
Nagisa Nasu, Atsuya Kanno,
Akihito Kohiga, Takahiro Koita

Graduate School of Doshisha University

1. 背景

クラウドの利用の拡大とコスト課題

世界のクラウドの支出の拡大



https://www.gartner.com/en/newsroom/press-releases/2024-11-19-gartner-forecasts-worldwide-public-cloud-end-user-spending-to-total-723-billion-dollars-in-2025

コスト管理の難しさ

85%

クラウド支出管理が課題

https://www.flexera.com/about-us/press-center/flexera-finds-cloud-value-is-rising-while-ai-waste-grows

スポットインスタンス

1. 背景

スポットインスタンス

余剰リソースを

最大90%割引で利用



余剰リソースが

少なくなると中断



1. 背景

スポットインスタンス

余剰リソースを
最大90%割引で利用



余剰リソースが
少なくなると中断



1. 背景

スポットインスタンス

余剰リソースを

最大90%割引で利用



余剰リソースが

少なくなると中断



1. 背景

スポットインスタンス

余剰リソースを

最大90%割引で利用



余剰リソースが

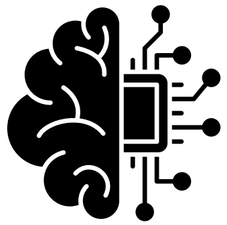
少なくなると中断



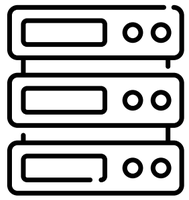
1. 背景

スポットインスタンスの用途

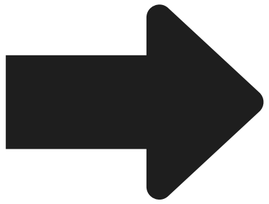
従来の用途



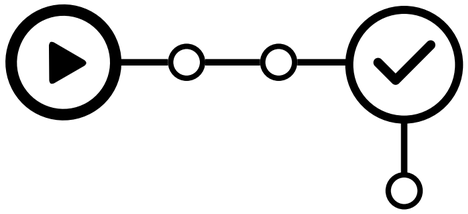
ML/GPU処理



大規模バッチ処理



近年広がっている用途



CI/CD



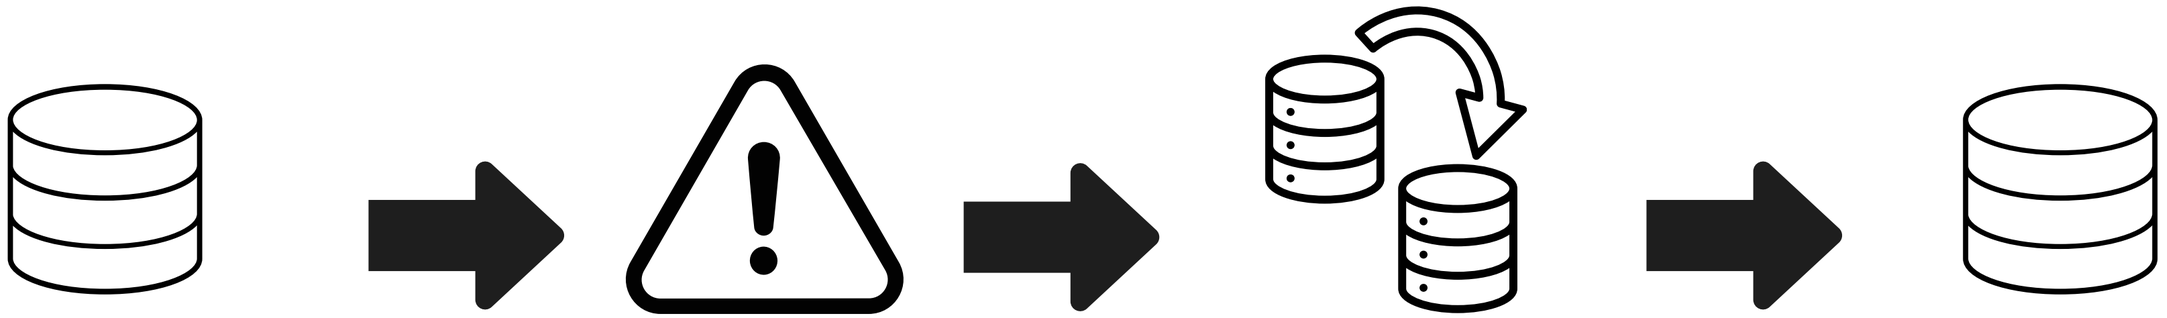
自動テスト

短時間ワークロード

(数分から1時間)

1. 背景

既存戦略の限界



スポットインスタンス

中断通知

(中断2分前)

移行作業

(バックアップなど)

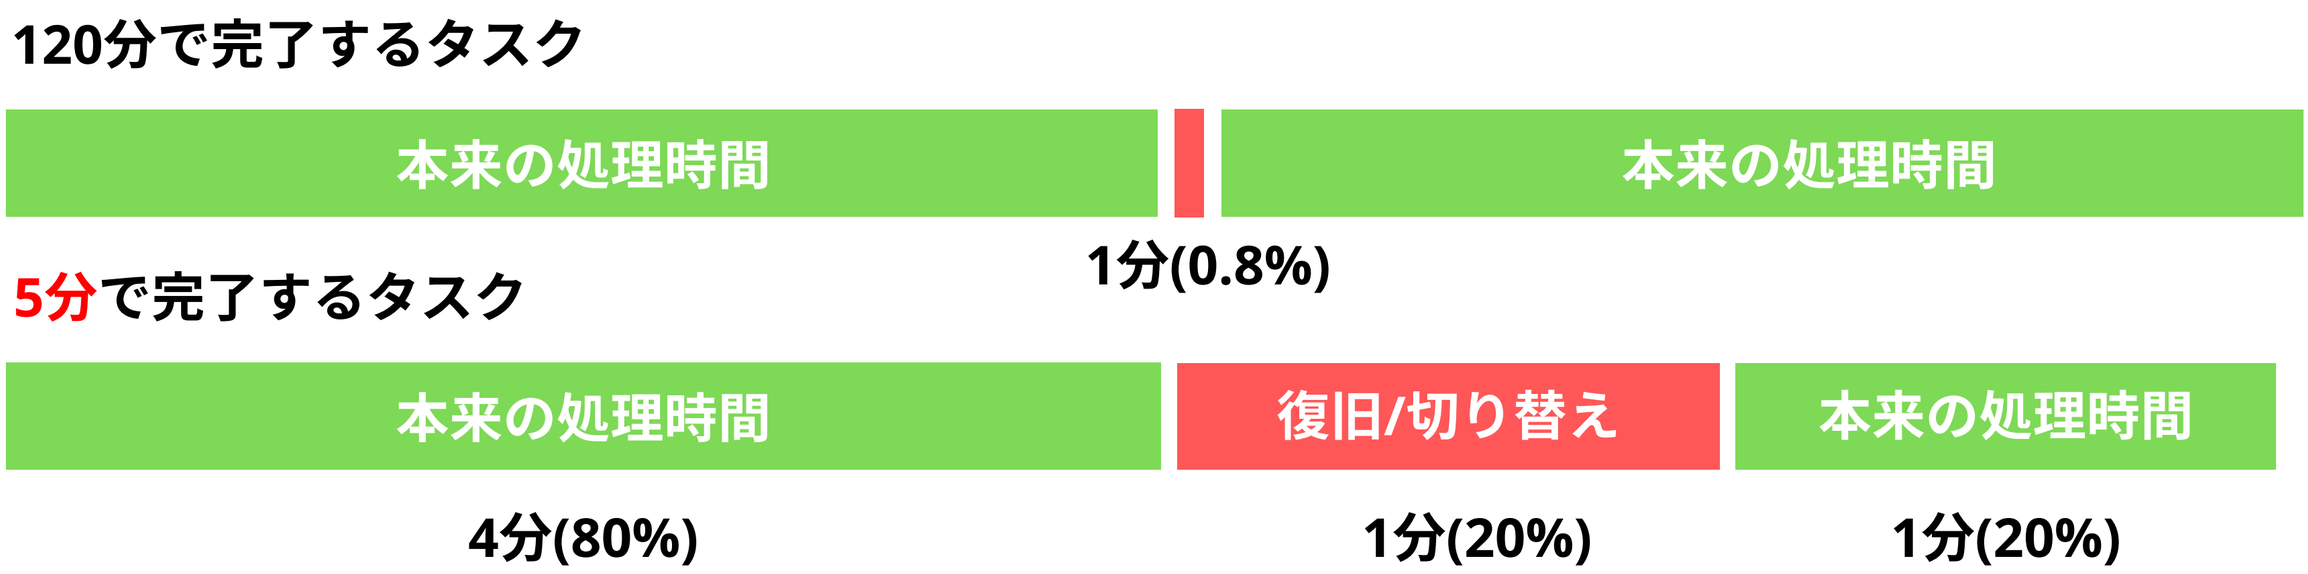
別環境へ

中断されることを前提とした、やむを得ない戦略

1. 背景

短時間ワークロードでは、復旧/切り替えの割合が高く

処理時間とコストの増加につながる



数分〜1時間のジョブでは、checkpointや再起動の時間が

ジョブ本体に対して、無視できない割合になる

1. 背景

短時間ワークロードでは、

切り替えるのではなく、完了できる

5分で完了するタスク



5分(100%)

2. 既存研究 ①

AWS SPSを利用して、移行先インスタンスの選定

※AWS SPS：Spot起動可能性を1～10で示すスコア

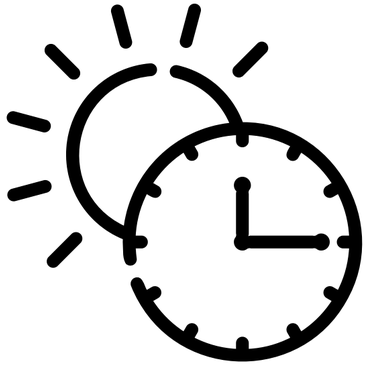


SPSは起動時点の指標であり、実行後に最後まで継続できるかは示さない

Katayama, D., Kasai, K., Koita, T.: Migration Destination Selection Algorithm for Spot Instances using SPS. In: 2022 IEEE International Conference on Big Data (Big Data), pp. 6690–6692. IEEE, Osaka (2022). https://doi.org/10.1109/BigData55660.2022.10020520

2. 既存研究 ②

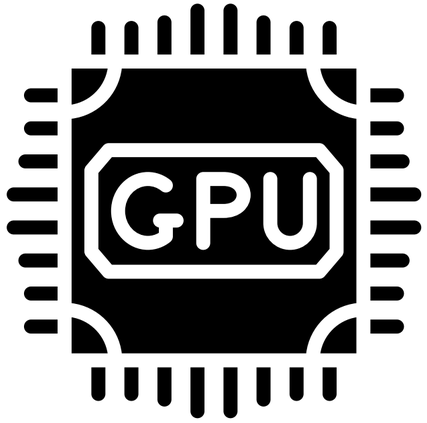
スポットインスタンスの中断が時間帯・地域・インスタンスタイプに変動



日中の中断率が高い



地域によって中断率が異なる



GPUインスタンスの中断率が高い

スポットインスタンスの中断率は、一定ではない

Lee, S., Hwang, J., Lee, K.: SpotLake: Diverse Spot Instance Dataset Archive Service. In: 2022 IEEE International Symposium on Workload Characterization (IISWC), pp. 242–255. IEEE (2022). https://doi.org/10.1109/IISWC55918.2022.00029

2. 既存研究の限界

	既存研究①	既存研究②	本研究
起動できるか	○	×	×
中断されやすいか	×	○	×
完了まで生き残るか	×	×	○

「いつ・どこで・どのタイプで起動させれば、タスクの完了まで生き残るか」

を判断することができない

3. 目的

短時間ワークロードが、
「いつ・どこで・どのタイプで起動させれば、タスクの完了まで生き残るか」
を判断できるスポットインスタンスの選択戦略を導く

4. アプローチ

step:1　完了可能性を定量化する指標を定義

step:2　AWS 上で時間帯 × 地域 × タイプ × デットラインで実測

step:3　実測結果から選択戦略を導出

4. アプローチ

step:1　　完了可能性を定量化する指標を定義

step:2　　AWS 上で時間帯 × 地域 × タイプ × デットラインで実測

step:3　　実測結果から選択戦略を導出

4. アプローチ

step1: 完了可能性を定量化する指標を定義

$F_{comp}(d)$: 起動後d分後生存する確率

d	想定ワークロード
5分	ユニット・リントテスト
10分	ビルド
30分	ECEテスト・ETL
60分	回帰テスト、短期間バッチ、機械学習

4. アプローチ

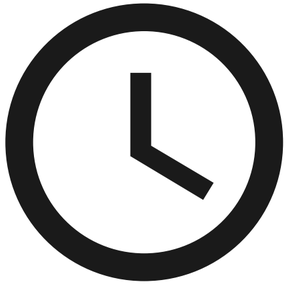
step:1　完了可能性を定量化する指標を定義

step:2　AWS 上で時間帯 × 地域 × タイプ × デットラインで実測

step:3　実測結果から選択戦略を導出

4. アプローチ

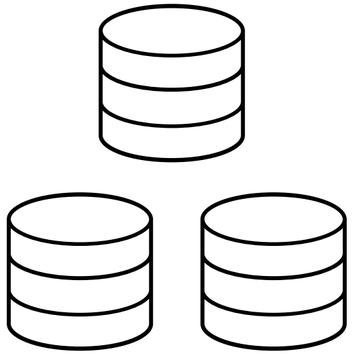
step2: AWS 上で時間帯 × リージョン × タイプ × デットラインで実測



時間帯



リージョン



インスタンスタイプ



デットライン(d)

4. アプローチ

step:1　完了可能性を定量化する指標を定義

step:2　AWS 上で時間帯 × 地域 × タイプ × デットラインで実測

step:3　実測結果から選択戦略を導出

4. アプローチ

step3: 実測結果から選択戦略を導出



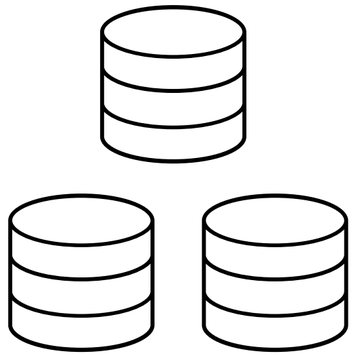
時間帯

完了しやすい時間帯



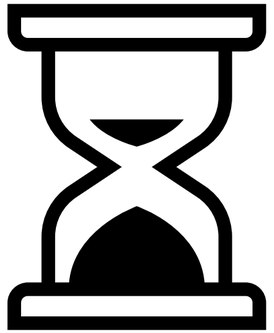
リージョン

完了しやすいリージョン



インスタンスタイプ

完了しやすインスタンスタイプ



デットライン(d)

完了しやすい時間帯

短時間ワークロード(d)が、
「いつ・どこで・どのタイプで起動させれば、タスクの完了まで生き残るか」
を判断できるスポットインスタンスの選択戦略を導く

5. 指標の定義

スポットインスタンスが、起動後d分後生存する確率

$$F_{comp}(d) = \frac{N_{succ} - N_{int}(d)}{N_{succ}}$$

N_{succ} = 起動に成功したスポットインスタンスの数

$N_{int}(d)$ = N_{succ} の中でd分前に中断されたスポットインスタンスの数

d = ワークロードの実行時間（5、10、30、60 分）

5. 指標の定義

例: スポットインスタンスが、起動後30分後生存する確率

100台



起動に成功した
スポットインスタンス

85台 (15台が中断)



30分後に生存した
スポットインスタンス

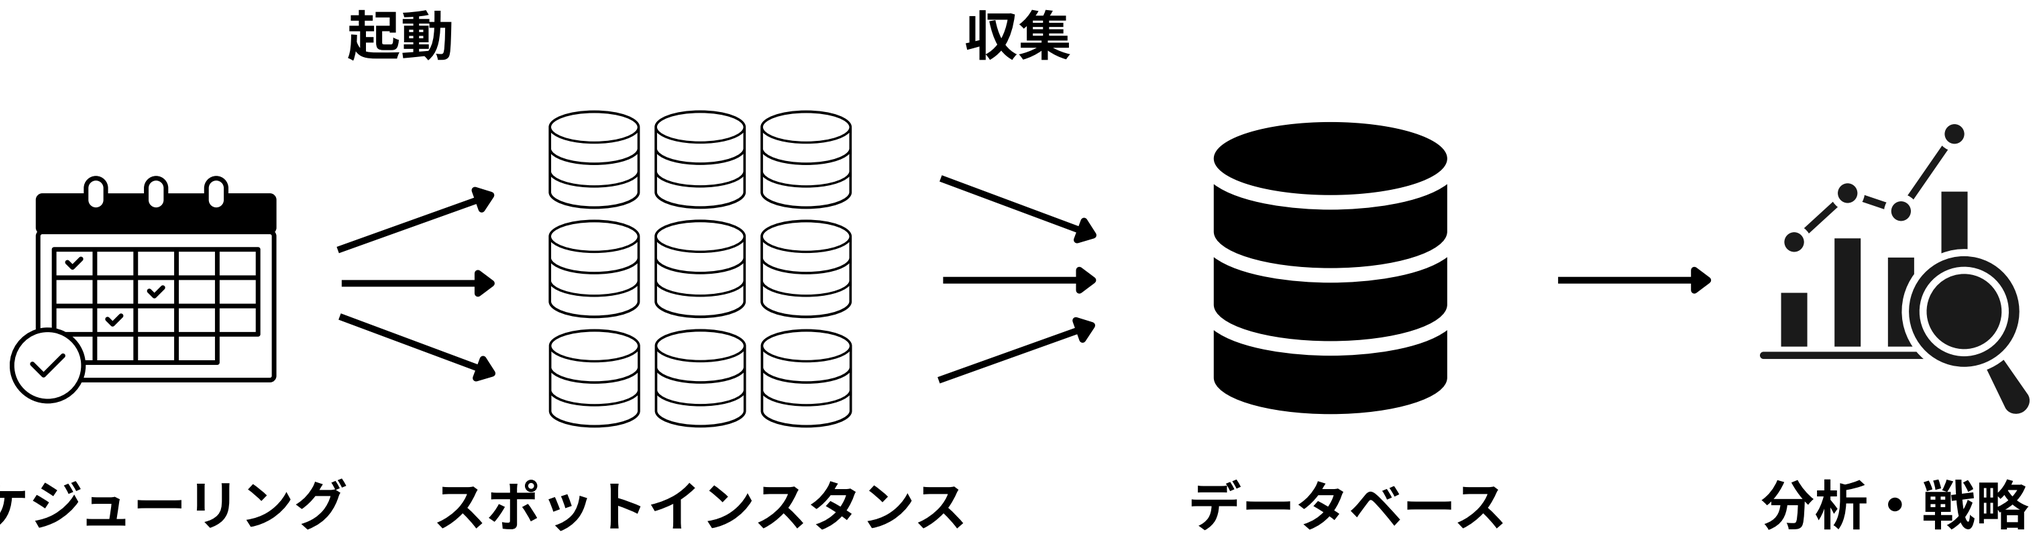
$$F_{comp}(30) = \frac{100 - 15}{100} = 0.85$$

起動に成功したスポットインスタンスの85%が、

30分間生存することができ、ワークロードを完了できる

6. 測定フレームワーク

スポットインスタンスの状態をデータベースで管理



7. 実験設定

192条件（4 time brand × 4 region × 3 instance type × 4 deadline)



時間帯

Night (00 ~ 06)

Morning (06 ~ 12)

Afternoob (12 ~ 18)

Evening (18 ~ 24)



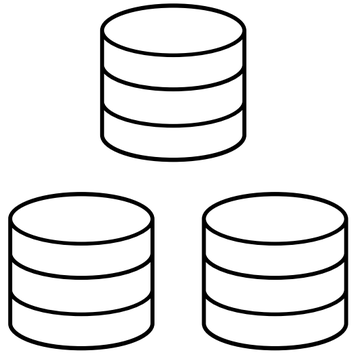
リージョン

N. Virginia

Ireland

Tokyo

Singapore



インスタンスタイプ

c6a.large

g4dn.xlarge

t3.micro



デットライン(d)

5 min

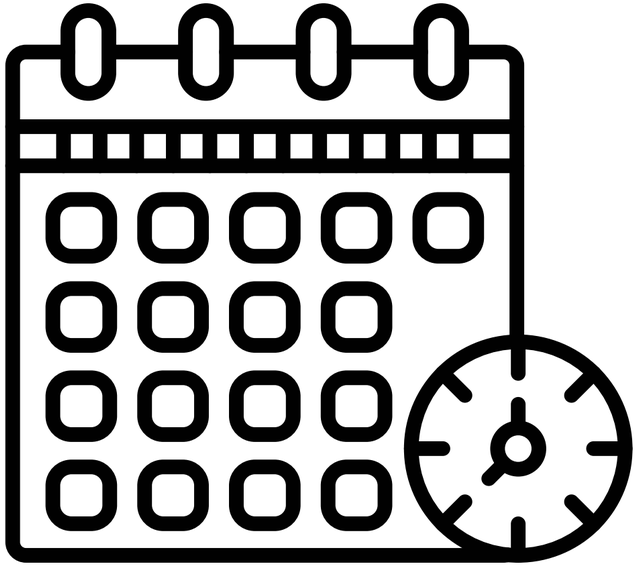
10 min

30 min

60 min

7. 実験設定

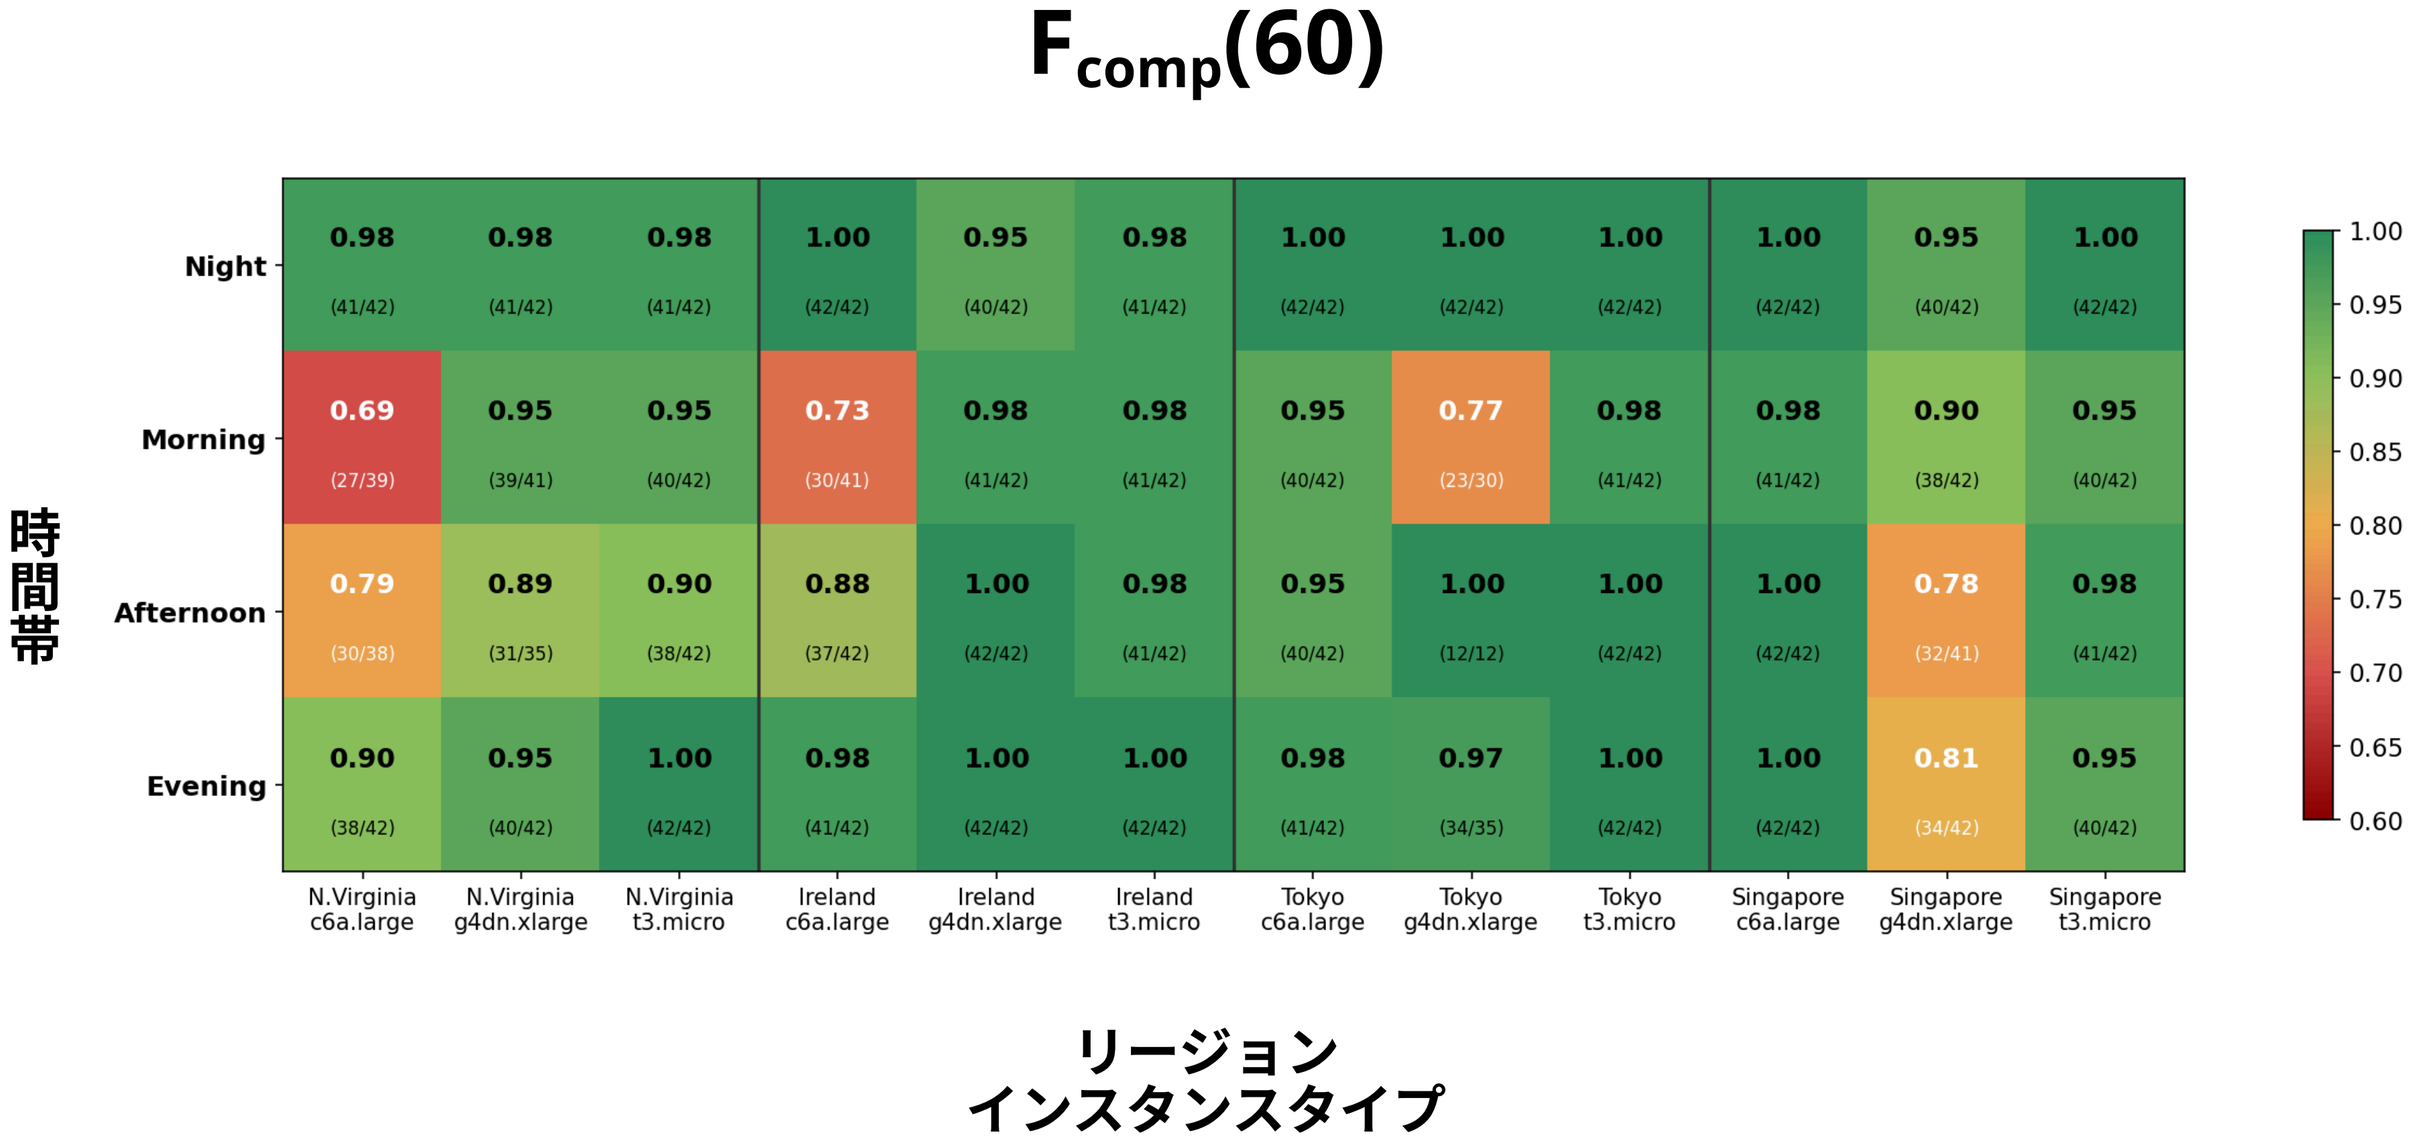
観測期間



05/19/2026 ~ 05/25/2025

(7 days)

8. 結果と戦略


$F_{comp}(60)$
時間帯
Night
Morning
Afternoon
Evening
0.98 (41/42) 0.98 (41/42) 0.98 (41/42) 1.00 (42/42) 0.95 (40/42) 0.98 (41/42) 1.00 (42/42) 1.00 (42/42) 1.00 (42/42) 1.00 (42/42) 0.95 (40/42) 1.00 (42/42)
0.69 (27/39) 0.95 (39/41) 0.95 (40/42) 0.73 (30/41) 0.98 (41/42) 0.98 (41/42) 0.95 (40/42) 0.77 (23/30) 0.98 (41/42) 0.98 (41/42) 0.90 (38/42) 0.95 (40/42)
0.79 (30/38) 0.89 (31/35) 0.90 (38/42) 0.88 (37/42) 1.00 (42/42) 0.98 (41/42) 0.95 (40/42) 1.00 (12/12) 1.00 (42/42) 1.00 (42/42) 0.78 (32/41) 0.98 (41/42)
0.90 (38/42) 0.95 (40/42) 1.00 (42/42) 0.98 (41/42) 1.00 (42/42) 1.00 (42/42) 0.98 (41/42) 0.97 (34/35) 1.00 (42/42) 1.00 (42/42) 0.81 (34/42) 0.95 (40/42)
N.Virginia c6a.large
N.Virginia g4dn.xlarge
N.Virginia t3.micro
Ireland c6a.large
Ireland g4dn.xlarge
Ireland t3.micro
Tokyo c6a.large
Tokyo g4dn.xlarge
Tokyo t3.micro
Singapore c6a.large
Singapore g4dn.xlarge
Singapore t3.micro
1.00
0.95
0.90
0.85
0.80
0.75
0.70
0.65
0.60
リージョン
インスタンスタイプ

8. 結果と戦略

ユースケース

ユースケース	d	固定	選択
CI/CD	5 min	-	全て
定期集計バッチ (業務開始時)	10 min	Morning (時間帯固定)	時間帯 リージョン
ETL (データローカル)	30 min	Tokyo (リージョン固定)	インスタンスタイプ リージョン
機械学習 (GPU訓練)	60 min	g4dn.xlarge (インスタンスタイプ固定)	インスタンスタイプ 時間帯

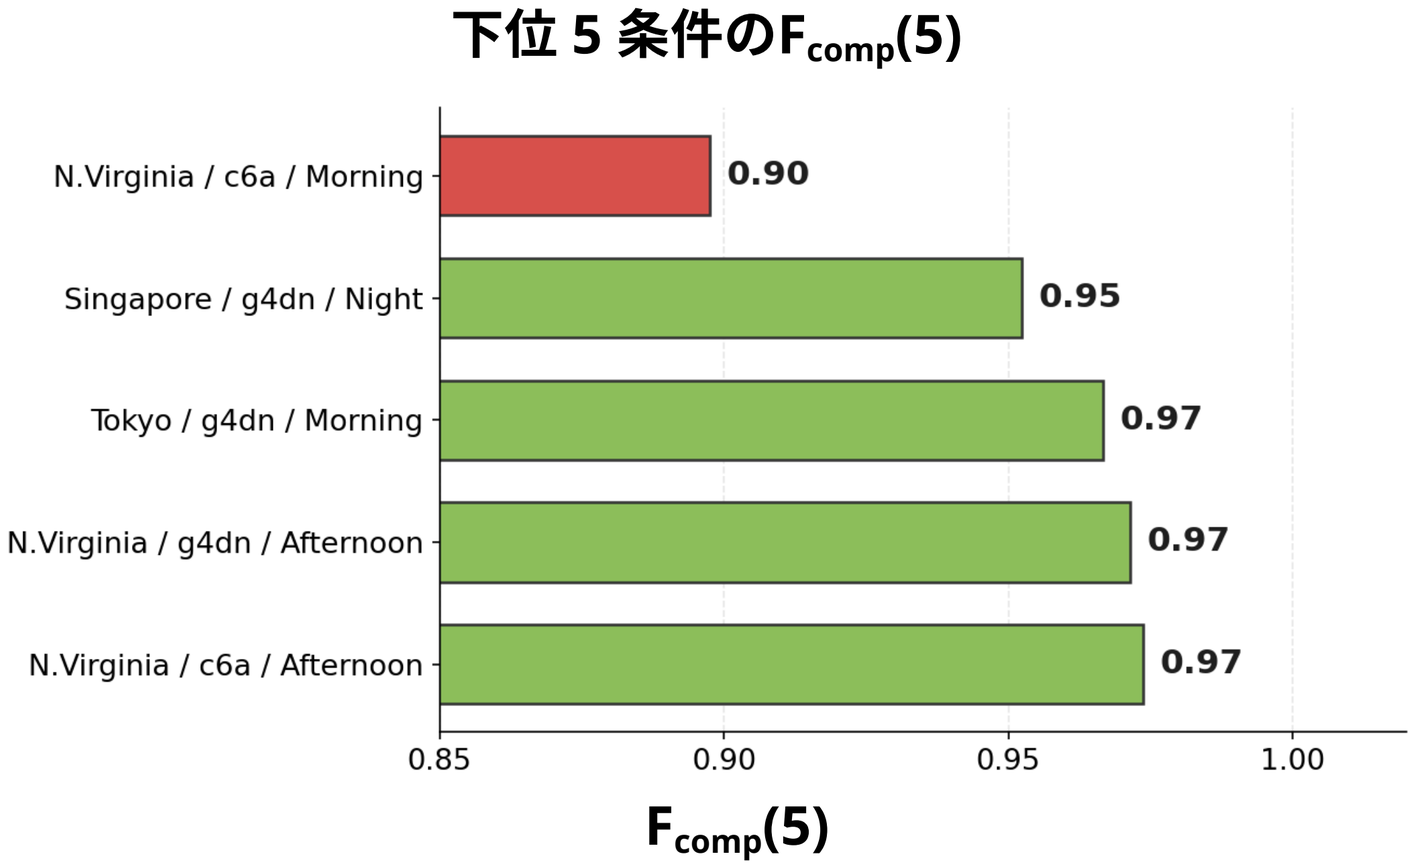
8. 結果と戦略

ユースケース

ユースケース	d	固定	選択
CI/CD	5 min	-	全て
定期集計バッチ (業務開始時)	10 min	Morning (時間帯固定)	時間帯 リージョン
ETL (データローカル)	30 min	Tokyo (リージョン固定)	インスタンスタイプ リージョン
機械学習 (GPU訓練)	60 min	g4dn.xlarge (インスタンスタイプ固定)	インスタンスタイプ 時間帯

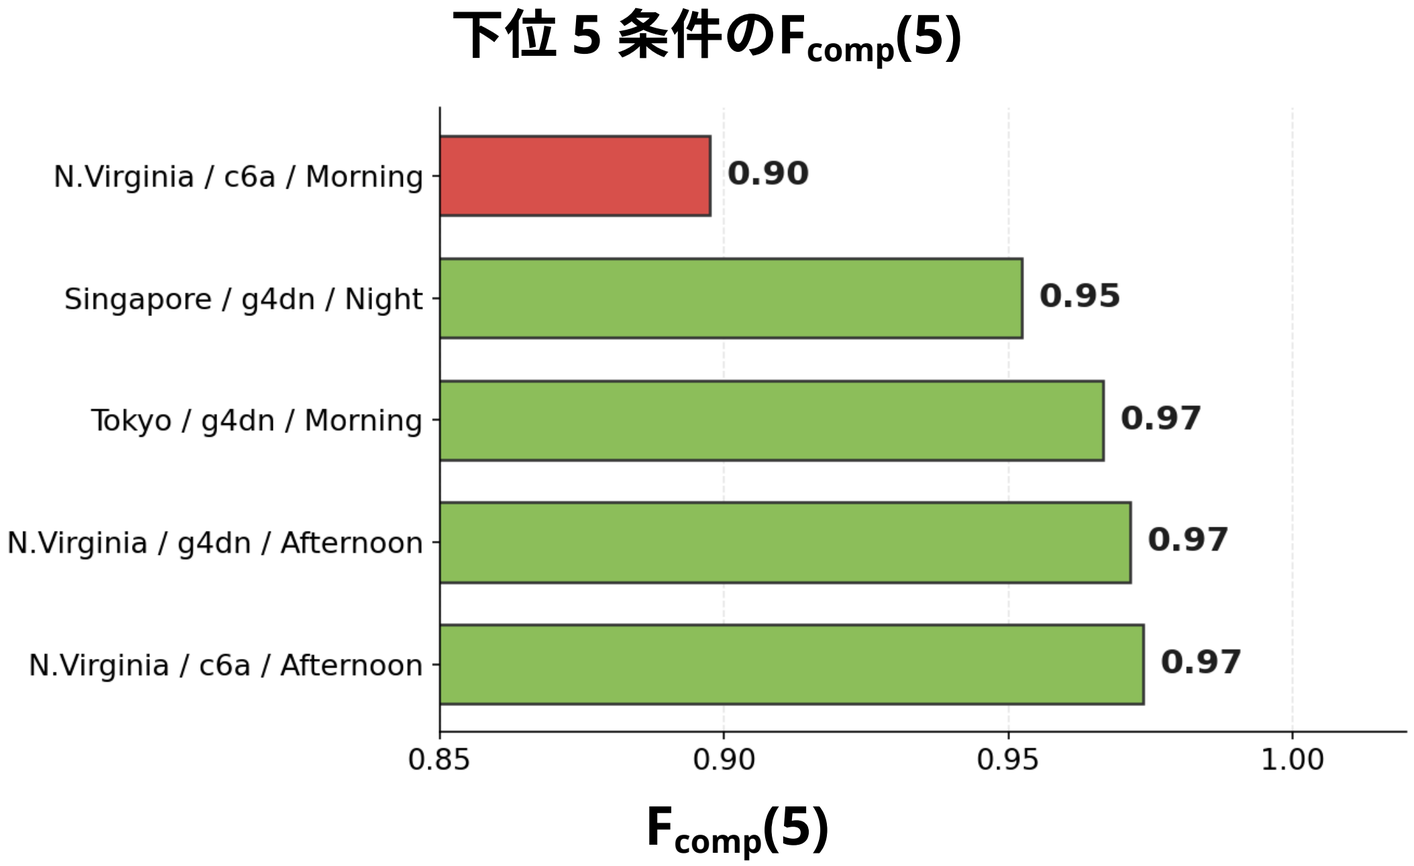
8. 結果と戦略

CI/CD


下位 5 条件のF_comp(5)
N.Virginia / c6a / Morning
Singapore / g4dn / Night
Tokyo / g4dn / Morning
N.Virginia / g4dn / Afternoon
N.Virginia / c6a / Afternoon
0.90
0.95
0.97
0.97
0.97
0.85
0.90
0.95
1.00
F_comp(5)

8. 結果と戦略

CI/CD



戦略：N. Virginia の c6a.large の Morning を避ける

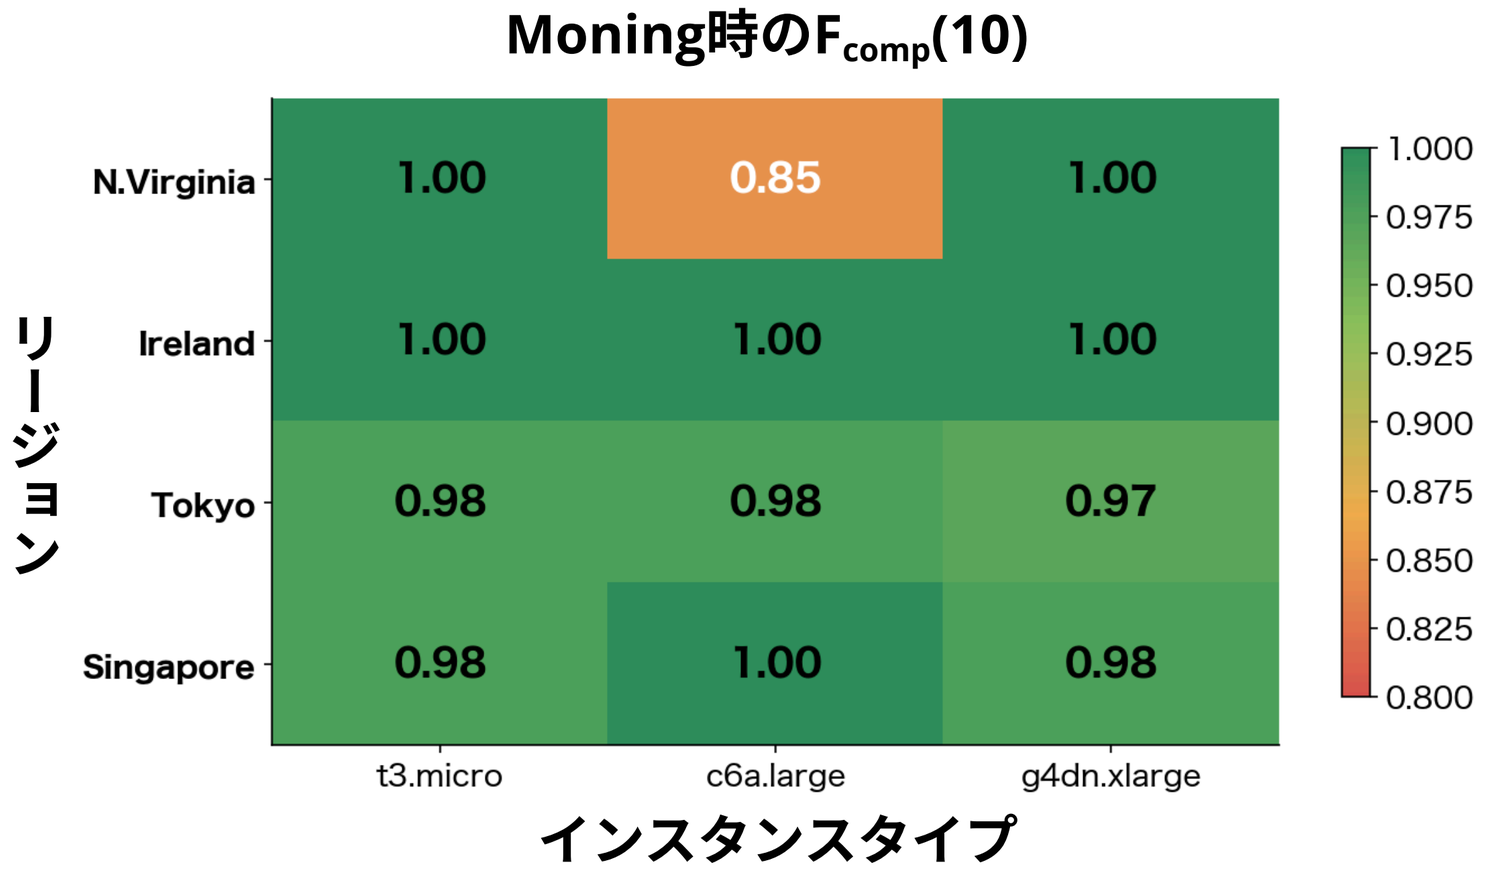
8. 結果と戦略

ユースケース

ユースケース	d	固定	選択
CI/CD	5 min	-	全て
定期集計バッチ (業務開始時)	10 min	Morning (時間帯固定)	時間帯 リージョン
ETL (データローカル)	30 min	Tokyo (リージョン固定)	インスタンスタイプ リージョン
機械学習 (GPU訓練)	60 min	g4dn.xlarge (インスタンスタイプ固定)	インスタンスタイプ 時間帯

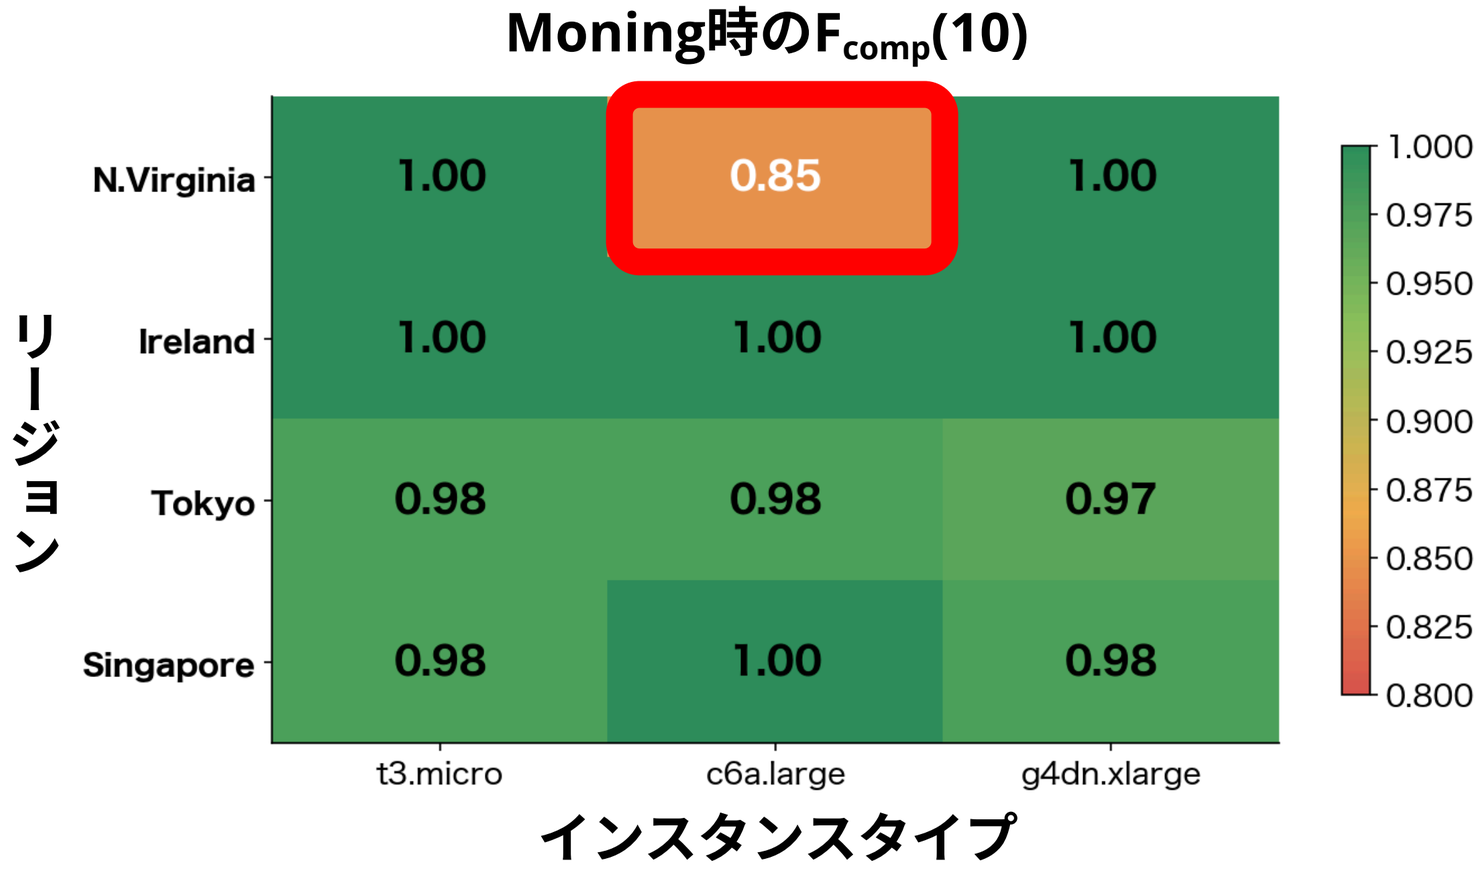
8. 結果と戦略

定期集計バッチ (業務開始時)



8. 結果と戦略

定期集計バッチ (業務開始時)



戦略：N.Virginiaのc6a.largeを避ける

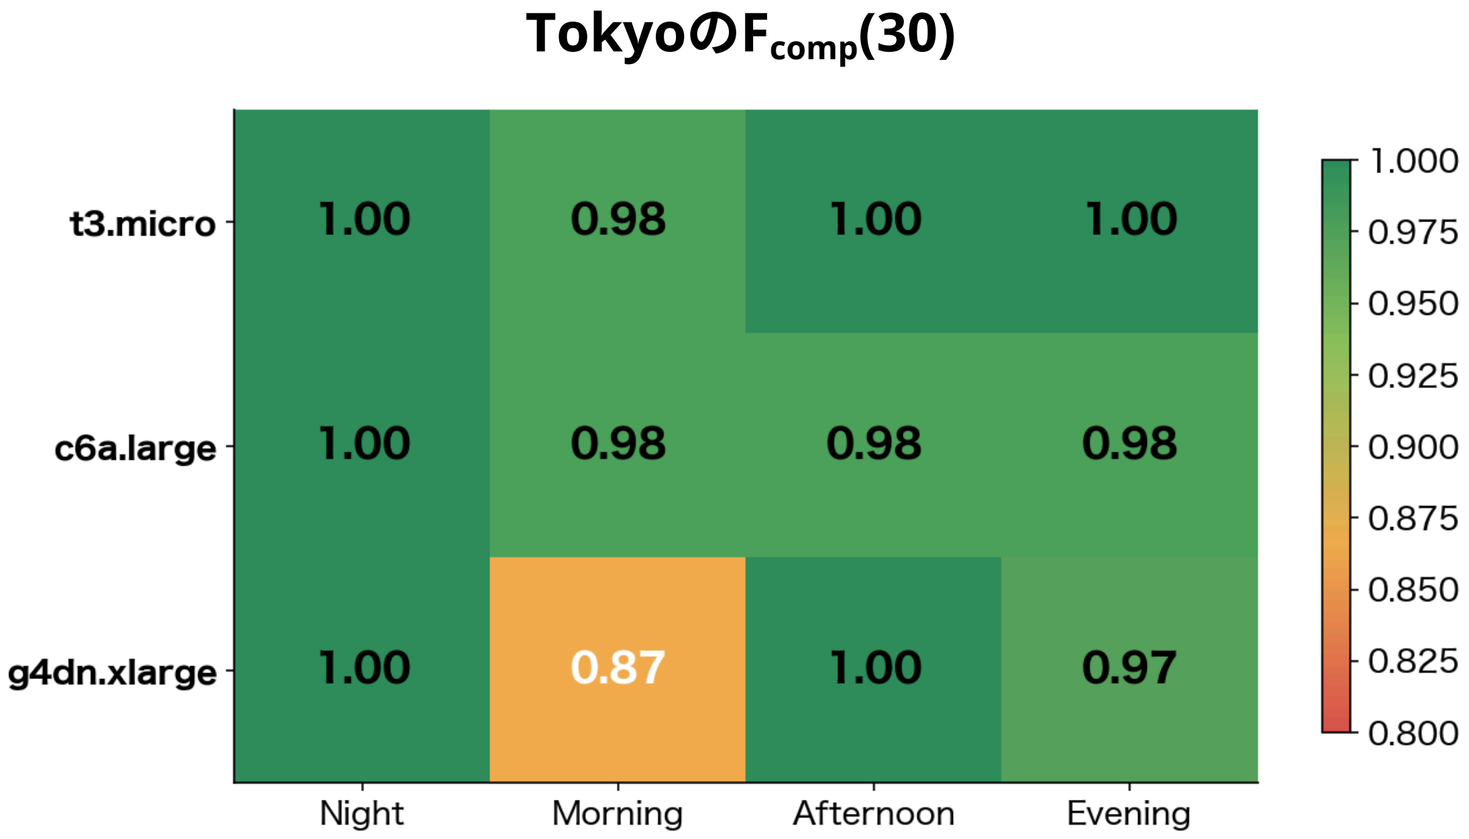
8. 結果と戦略

ユースケース

ユースケース	d	固定	選択
CI/CD	5 min	-	全て
定期集計バッチ (業務開始時)	10 min	Morning (時間帯固定)	時間帯 リージョン
ETL (データローカル)	**30 min**	**Tokyo (リージョン固定)**	**インスタンスタイプ リージョン**
機械学習 (GPU訓練)	60 min	g4dn.xlarge (インスタンスタイプ固定)	インスタンスタイプ 時間帯

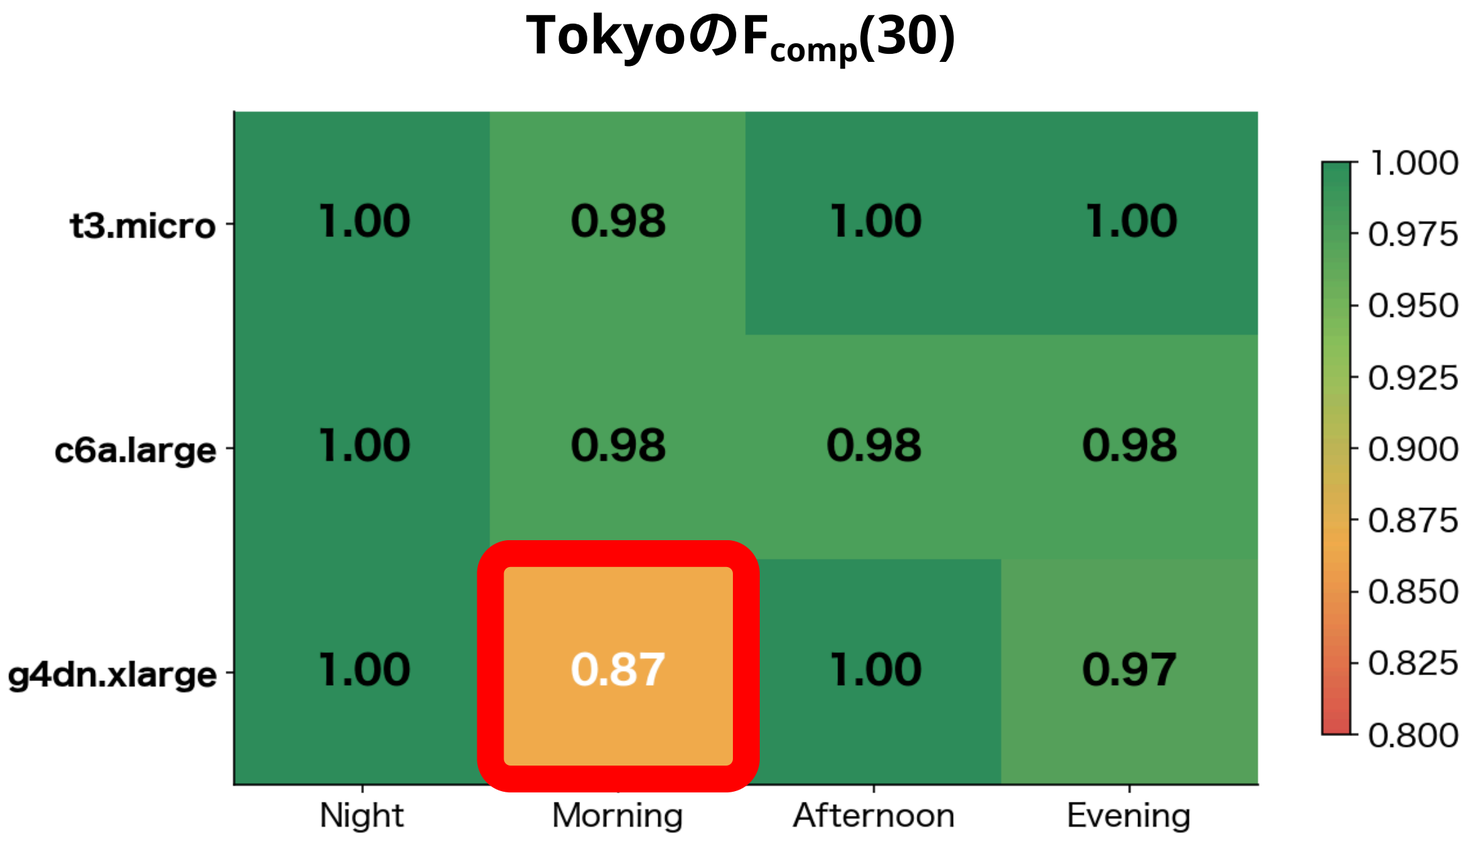
8. 結果と戦略

ETL(データローカル)



8. 結果と戦略

ETL(データローカル)



戦略：Morningのg4dn.xlargeを避ける

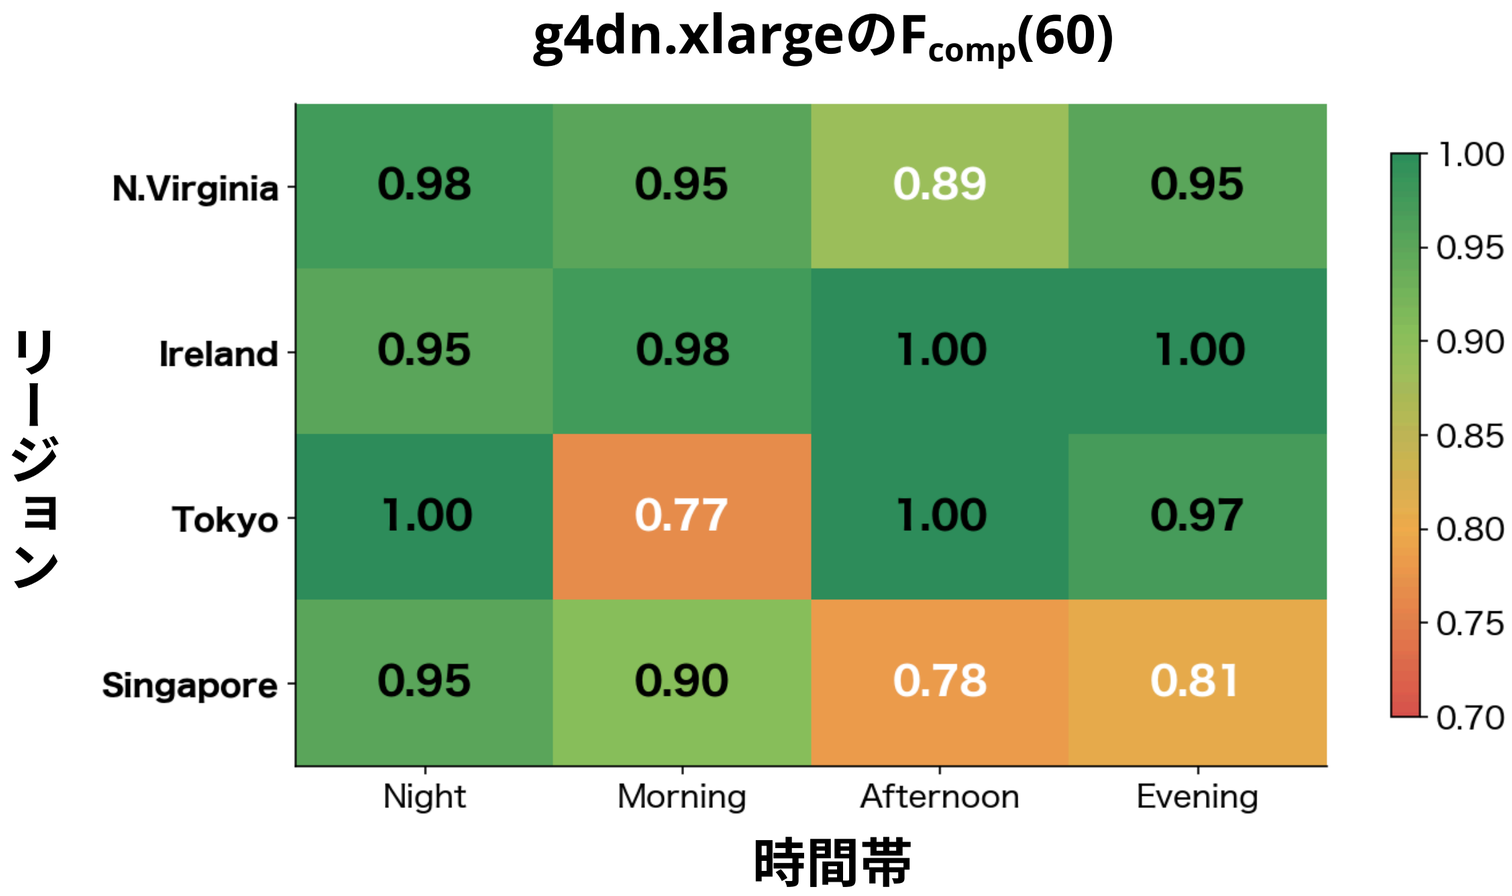
8. 結果と戦略

ユースケース

ユースケース	d	固定	選択
CI/CD	5 min	-	全て
定期集計バッチ (業務開始時)	10 min	Morning (時間帯固定)	時間帯 リージョン
ETL (データローカル)	30 min	Tokyo (リージョン固定)	インスタンスタイプ リージョン
機械学習 (GPU訓練)	**60 min**	**g4dn.xlarge (インスタンスタイプ固定)**	**インスタンスタイプ 時間帯**

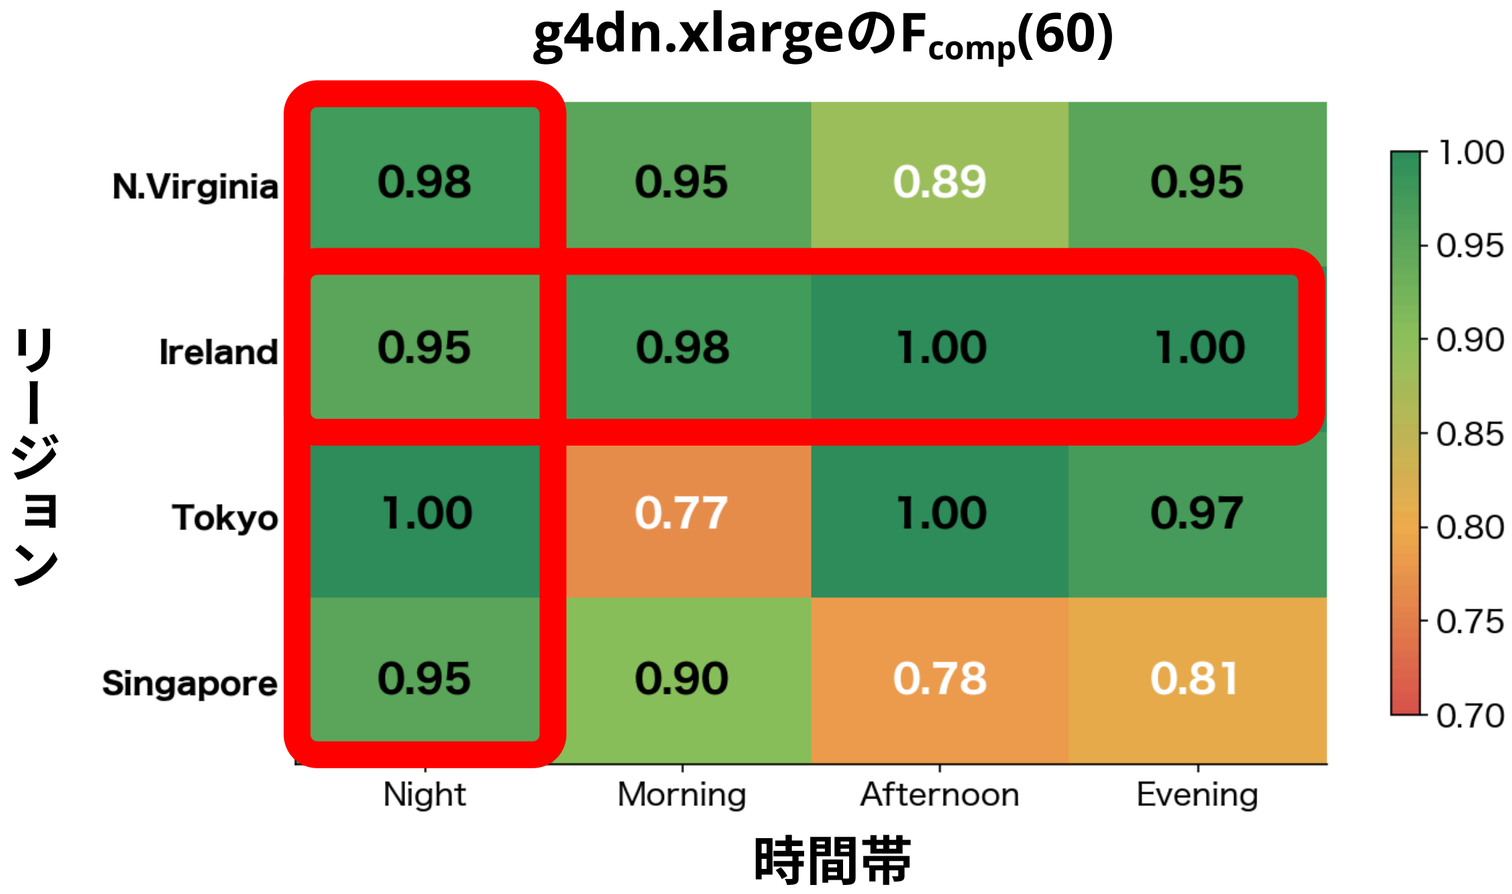
8. 結果と戦略

機械学習 (GPU訓練)



8. 結果と戦略

機械学習 (GPU訓練)



戦略：Night または Irelandを選択

8. 結果と戦略

ユースケース

ユースケース	d	固定	選択
CI/CD	5 min	-	全て
定期集計バッチ (業務開始時)	10 min	Morning (時間帯固定)	時間帯 リージョン
ETL (データローカル)	30 min	Tokyo (リージョン固定)	インスタンスタイプ リージョン
機械学習 (GPU訓練)	60 min	g4dn.xlarge (インスタンスタイプ固定)	インスタンスタイプ 時間帯

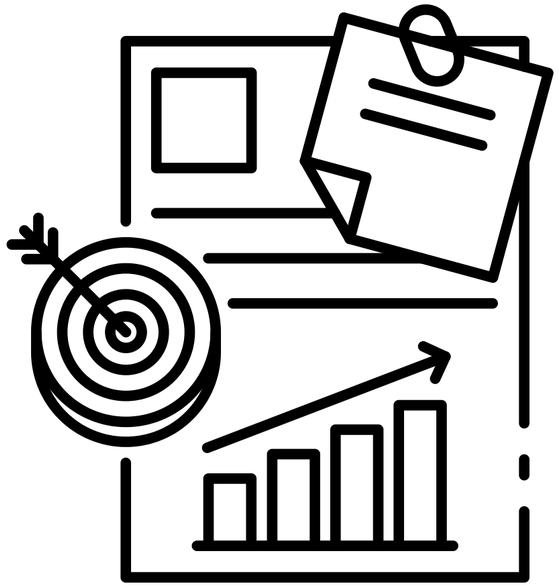
8. 結果と戦略

ユースケース

ユースケース	d	戦略
CI/CD	5 min	N.Virginiaのc6a.largeを避ける
定期集計バッチ (業務開始時)	10 min	N.Virginiaのc6a.largeを避ける
ETL (データローカル)	30 min	Morningのg4dn.xlargeを避ける
機械学習 (GPU訓練)	60 min	Night または Irelandを選択

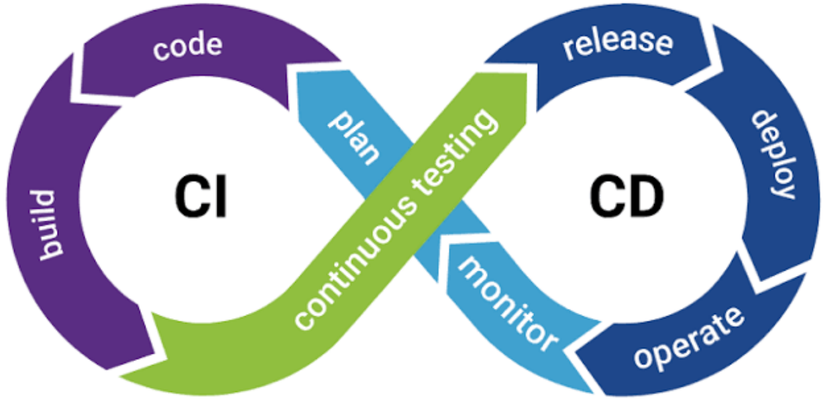
8. 今後の展望

実ワークロード検証



戦略

（本研究）



実ワークロードで検証

https://www.blackduck.com/ja-jp/glossary/what-is-cicd.html

Thank you