インスタンスタイプの CPU・GPU 使用率による性能とコスト評価

Performance and cost evaluation based on instance type CPU/GPU usage rate

那須渚 [1] 小川光貴 [2] 笠井 菊平 [2] 小板隆浩 [2]
Nagisa Nasu Mitsuki Ogawa kippei Kasai Takahiro Koita

同志社大学 [1]
Doshisha University

同志社大学大学院 [2]
Graduate School of Doshisha University

1 はじめに

近年，クラウドコンピューティングの普及により，多くの企業や研究機関が Amazon Web Services（AWS）や Azure などのクラウドサービスを活用するようになった．クラウドサービスは，多様なインスタンスタイプを提供しており，ユーザは自分の利用目的にあったインスタンスを選択できる．そのため，適切なインスタンスタイプを選定するためには，指標が必要となる．先行研究 [1] では，生成時間や処理時間などの時間軸による評価が多い．本研究では，新たな評価軸として CPU，GPU 使用率，価格を採用し，利用目的に応じたインスタンスタイプを選択可能にする．

2 実験概要

本研究では，AWS の仮想サーバーサービスである EC2 を活用し，異なるタイプのインスタンスの性能評価を行う．評価対象は，汎用型インスタンスの t2.2xlarge，高性能 CPU を搭載した c5.2xlarge，および GPU を搭載している g4dn.2xlarge と p3.2xlarge の 4 種類である．これらのインスタンスに対して画像生成モデル Stable Diffusion を用いたタスクを割り当て，それぞれの処理能力を CPU 利用率，GPU 利用率，価格により比較し，性能評価を行う．

3 結果と考察

表 1 に，各インスタンスごとのタスク処理中の CPU および GPU 使用率を示す．同様に，表 2 に，画像の生成時間と 1 時間あたりのインスタンス価格を示す．また図 1 に，画像生成時の GPU 使用率の変化を示す．

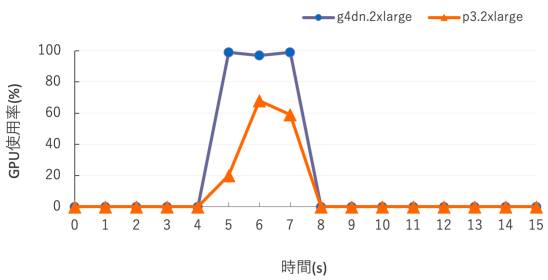


図 1 時間と GPU 使用率

表 1 CPU 使用率と GPU 使用率平均

タイプ	CPU 使用率 (%)	GPU 使用率 (%)
t2.2xlarge	95.28	-
c5.2xlarge	93.61	-
g4dn.2xlarge	13.15	98.33
p3.2xlarge	10.94	49.00

表 2 生成時間と価格

タイプ	生成時間 (s)	価格 ($/時間)
t2.2xlarge	95.0	0.486
c5.2xlarge	84.5	0.428
g4dn.2xlarge	3.9	1.015
p3.2xlarge	2.5	4.194

表 2 より GPU を搭載したインスタンスは生成時間が短く，画像生成において非常に重要である．さらに，表 1 より，一定の CPU 使用率が観察された．これは，画像生成プロセスが GPU だけでなく，CPU の性能にも依存することを示している．CPU はデータの前処理や I/O 操作を担当するため，その性能も重要である．また図 1 より，p3 インスタンスの GPU 使用率が約 60 %であることから，p3 の計算能力が画像生成の要求を上回っている可能性がある．一方で，p3 の価格は g4dn の約 4 倍で，生成時間は約半分である．コスト効率を考慮すると g4dn の方が適していると言える，

4 おわりに

本研究により，画像生成におけるインスタンスタイプの選択に関して，CPU 利用率および GPU 使用率とコストの観点から重要な洞察が得られた．今後の研究では，メモリの大きさや I/O 性能など，新たな評価軸の設定，負荷の違いによるインスタンスタイプの評価，及び比較検討を行い，利用目的に応じた最適なインスタンス選択可能にする．

参考文献

[1] 小川光貴，江南彪斗，片岡蒼汰，小板隆浩：深層学習における GPU インスタンスの性能評価，第 31 回マルチメディア通信と分散処理ワークショップ論文集，pp.238-240，2023.