複数クラウドプロバイダーにおける異なる画像生成の性能とコストの比較分析

2021 年度 1053 番 那須渚

1 はじめに

近年，クラウドコンピューティングの普及により，Amazon Web Services(AWS), Microsoft Azure, Google Cloud Platform(GCP) などのクラウドプロバイダーが企業，研究機関で広く使用されている．これらのクラウドプロバイダーは，用途に応じて最適なインスタンスタイプを選択できる多様なオプションを提供している [1]．しかし，適切なインスタンスの選定には，性能とコストの両方を考慮した詳細な評価が必要となる．本研究では，このギャップを埋めるために，性能とコストの観点から評価し，比較分析を行う，特にディープラーニングの 1 つである画像生成タスクに焦点を当てる．各クラウドプロバイダーのインスタンスがどのような性能を発揮するかを検証し，その結果を基にクラウドプロバイダー利用者が性能，コスト，費用対効果の観点からそれぞれ最適なインスタンスを選択できるようにするための明確な基準を提供することが本研究の目的である．

2 実験概要

本研究では，複数のクラウドプロバイダーから選定したインスタンスを用いて，Stable Diffusion Web UI というユーザーインターフェースを通じて画像生成タスクを行う．全実験において同一モデルとプロンプトを使用する．画像サイズは 512^2, 1024^2, 1536^2, 2048^2の四種類を設定し，それぞれのサイズで画像を生成する．各サイズで生成された画像の性能，コスト，および費用対効果を評価し，これらの観点でそれぞれどのインスタンスが最適であるかを明らかにする．

本研究では，性能・コスト・費用対効果を以下に定義する．

(1) 性能：画像が生成されるまでの時間 (s)

(2) コスト：生成時間あたりのインスタンス利用にかかった費用 ($)

(3) 費用対効果：性能の増加率とコストの増加率の比率

3 予備実験

クラウドプロバイダーには 500 種類以上のインスタンスが存在し，その多様性から全てのインスタンスを調査することは困難である．画像生成タスクにおいて，GPU 搭載インスタンスが高性能であるとされているが，コストの評価は不十分である．したがって，予備実験では，GPU 搭載インスタンスがコスト削減に寄与することを示すことを目的とする．インスタンスの選定に際しては，GPU を搭載していない汎用的なインスタンス (t2.2xlarge，D8s_v3, n1-standard-8) と機械学習 (深層学習) 向けに設計された GPU 搭載インスタンス (g4dn.2xalrge, NC8as_T4_v3, n1-standard-8(GPU) を各サービスから一つずつ選択し，評価を実施した．結果を表 2 に示す．GPU インスタンスはコスト削減および性能向上において優れており，画像生成タスクにおいて，GPU 搭載のインスタンス使用が適切であること判明した．

表 1: 予備実験の結果

インスタンスタイプ	性能 (s)	コスト ($)	費用対効果
t2.2xlarge	127.60	17.24 x 10^{-3}	0.0015
g4dn.2xalrge	3.42	0.96 x 10^{-3}	1.0000
D8s_v3	245.07	35.13 x 10^{-3}	0.0003
NC8as_T4_v3	3.36	0.70 x 10^{-3}	1.3984
n1-standard-8	171.40	18.09 x 10^{-3}	0.0010
n1-standard-8(GPU)	3.42	0.74 x 10^{-3}	1.3127

表 2: 各サイズにおける評価

画像サイズ	性能	コスト	費用対効果
512^2	n1-standard-8（V100）	NC8as_T4_v3	n1-standard-8（V100）
1024^2	n1-standard-8（V100）	NC8as_T4_v3	n1-standard-8（V100）
1536^2	n1-standard-8（V100）	NC8as_T4_v3	n1-standard-8（V100）
2048^2	n1-standard-8（V100）	NC8as_T4_v3	n1-standard-8（V100）

4 本実験

4.1 概要

インスタンスの選定について，予備実験から画像生成タスクにおいて GPU 搭載インスタンスがコスト削減と性能向上に寄与することが明らかになった．このため，GPU 搭載を基準に選定を行い，NVIDIA 製の GPU を採用している．データセンターにおける GPU のシェア率が 92% に達していることが選定の理由である．具体的には，NVIDIA Tesla T4 および NVIDIA Tesla V100 の 2 種類の GPU を主軸に設定している [2].

4.2 結果

1024^2 の画像サイズに関する結果を表 3 に示す．性能に関しては，n1-standard-8（V100）が処理時間 6.60 秒と最短であり，最も優れている．対照的に，n1-standard-8（T4）は処理時間が 22.10 秒と最長であり，性能が最も劣る．コストの観点からは，NC8as_T4_v3 が 4.09 $\times 10^{-3}$ ドルと最も低コストである．一方で，p3.2xlarge は 7.83 $\times 10^{-3}$ ドルと最も高コストである．費用対効果に注目すると，n1-standard-8（V100）は 3.36 の比率で最も高く，g4dn.2xlarge は 1.00 の比率で最も低い．これらの結果から，1024^2 の画像サイズに対してコストを最も重視する場合は NC8as_T4_v3 を，性能または費用対効果を最も重視する場合は，n1-standard-8(V100) を選択すべきであることが示された．

表 3: 1024^2の画像サイズの時の評価

インスタンスタイプ	性能 (s)	コスト ($)	費用対効果
g4dn.2xlarge	20.32	5.72 x 10^{-3}	1.00
p3.2xlarge	6.72	7.83 x 10^{-3}	2.21
NC8as_T4_v3	19.56	4.09 x 10^{-3}	1.46
n1-standard-8(T4)	22.10	4.48 x 10^{-3}	1.17
n1-standard-8(V100)	6.60	5.24 x 10^{-3}	3.36

4.3 考察

表 2 より, 画像サイズ 512^2, 1024^2, 1536^2, および 2048^2 に対して実施された評価では，n1-standard-8（V100）が最も優れた性能および費用対効果を示し，NC8as_T4_v3 が低コストであることが確認された．これらの結果から，画像サイズに関わらず，コストを最小化する目的で NC8as_T4_v3 の選択が推奨される．一方で，最大の性能および費用対効果を求める場合は，n1-standard-8（V100）の選定が適切であると考えられる．

5 まとめ

本研究では，画像生成タスクに特化して，複数のクラウドプロバイダーのインスタンスに対するコスト，性能，および費用対効果を詳細に評価し，各カテゴリにおいて最適なインスタンスを特定することに成功した．評価は，画像サイズ 512^2から 2048^2までの範囲で行われ，性能が最も高いインスタンス，コストが最も低いインスタンス，そして費用対効果が最も高いインスタンスが明確に識別された . このプロセスにより，クラウドを利用する者がクラウドプロバイダーを選択する際の明確な基準を提供することができた．

参考文献

[1] Prakarsh Kaushik, Ashwin Murali Rao, Devang Pratap Singh, Swati Vashisht, and Shubhi Gupta. Cloud computing and comparison based on service and performance between amazon aws, microsoft azure, and google cloud. *2021 International Conference on Technological Advancements and Innovations (ICTAI)*, 2021.

[2] Stefano Markidis, Steven Wei Der Chien, Erwin Laure, Ivy Bo Peng, and Jeffrey S. Vetter. Nvidia tensor core programmability, performance precision. *2018 IEEE International Parallel and Distributed Processing Symposium Workshops (IPDPSW)*, 2018.